

CV_05 TEAM PRESENTS

RAPID DEPLOYMENT STRATEGY

AI Engineering Team

"단순히 AI를 배우는 것이 아니라,
AI로 비즈니스 문제를 해결하는 법을 배웁니다."

- Boostcamp AI Tech Motto

| Team Dynamics: 4인 4색 & 1인 1GPU

⚠ Constraints (S/W)

- ✓ **부족한 인력:** 타 팀(6명) 대비 적은 인원(4명). 시간 부족이 가장 큰 약점.
- ✓ **Hardware Diversity:** 1인 1GPU 환경 (서버 3대 + 고성능 로컬 1대)로 병렬 실험 극대화.
- ✓ **Diversity:** 전공자의 이론적 배경 + 비전공자의 과감한 **Trial & Error**.

♟ Strategy (O/T)

- ✓ **Agile Decision:** 인원이 적어 의사결정이 빠름. "일단 돌려보자"는 접근이 SOTA 발견으로 이어짐.
- ✓ **Target:** Real-world Business Problem. 제한된 리소스 내 성과 창출.
- ✓ **Solution:** Top-down 전략. 검증된 SOTA 모델을 빠르게 적용하고 결과를 역분석.

| Collaboration: 4개의 실험실



Slack Canvas

'살아있는 실험 노트'

실험 전 설계와 예상 결과를 공유하고, Result Log(mAP, Loss)를 실시간 기록합니다.



Pragmatic Git

'속도를 위한 실리적 선택'

Merge Hell 방지. 불필요한 코드 병합을 생략하고 최종 결과물(Weights/CSV) 위주로 공유합니다.



Daily Report

'12/09 1위 달성 전략'

양상블 전략 성공 (Co-DETR 가중치 집중).
교훈: "애매한 평균보다 엘리트 중심이 낫다."

Strategic Blueprint: The Ensemble-First Approach

The Realization

"결국 끝은 앙상블이다."

- ✔ **Limit of Customization:** 짧은 시간 내에 개별 모델 구조를 대폭 수정하여 성능을 올리는 데는 한계가 있습니다.
- ✔ **Winning Formula:** 상위권 경쟁의 핵심은 결국 다양하고 강력한 모델들의 **Ensemble**에 있음을 조기에 파악했습니다.

Core Mission

"최고의 재료(Model)를 찾아라."

- ✔ **Priority:** 앙상블 효과를 극대화하기 위해 **다양성 (Diversity)**과 **개별 성능**이 보장된 모델을 확보하는 것이 최우선 과제였습니다.
- ✔ **Action:** 하나의 모델을 깊게 파기보다, **Broad Search**를 통해 앙상블 후보군을 빠르게 확보하는 전략을 수립했습니다.

SCENARIO

Solving Business Problems

"전처리된 데이터는 이미 도착했다."

우리는 학습용 과제 수행자가 아닌, **현업의 모델링 배포** 전담팀이라고 가정했습니다.

- ✓ **Mission:** 2주 안에 High-Performance Model 배포.
- ✓ **Goal:** Paper가 아닌 Product(제품) 납품.
- ✓ **Pivot:** Research (X) → Engineering (O).



Problem Definition: The Chaos




데이터의 난관 (Complexity)

- ✓ **Extreme Occlusion:** 객체들이 심하게 겹쳐있고 구겨져 있어 형태 식별이 어렵습니다.
- ✓ **High Density:** 하나의 이미지에 **최대 71개**의 객체가 밀집되어 있습니다.

Insight

"단순히 찾아내는 것을 넘어, 극한의 분리 능력이 필요하다." → Co-DETR 같은 Heavy Model 필수.

EDA Insight: The Class Imbalance Paradox



Hypothesis vs. Reality

⚠ Initial Observation

EDA 결과 심각한 **Class Imbalance**가 확인되었습니다. 일반적인 관점에서는 Oversampling 등 데이터 증강이 필수적이라 판단했습니다.


🔬 Baseline Experiment

그러나 증강 없이 베이스라인을 돌려본 결과, **Confusion Matrix** 상에서 소수 클래스도 매우 정확하게 분류해내는 것을 확인했습니다.

Decision: No Special Treatment

"일반적인 전처리 관습(Bias)보다, 실제 모델의 학습 결과(Data)를 믿기로 했습니다." 인위적 증강 없이 학습을 진행했습니다.

EDA Insight: The Class Imbalance Paradox



Hypothesis vs. Reality

⚠ Initial Observation

EDA 결과 심각한 **Class Imbalance**가 확인되었습니다. 일반적인 관점에서는 Oversampling 등 데이터 증강이 필수적이라 판단했습니다.

🔬 Baseline Experiment

그러나 증강 없이 베이스라인을 돌려본 결과, **Confusion Matrix** 상에서 소수 클래스도 매우 정확하게 분류해내는 것을 확인했습니다.

Decision: No Special Treatment

"일반적인 전처리 관습(Bias)보다, 실제 모델의 학습 결과(Data)를 믿기로 했습니다." 인위적 증강 없이 학습을 진행했습니다.

Execution Pipeline: Reverse Engineering

"최고를 가져와서 우리 것으로 만드는 것 또한 엔지니어링 능력입니다."

1. Shotgun Trial

Ultralytics (YOLO v11) 등
라이브러리 활용 Exhaustive
Search

2. Selection

생존 모델 선정
(Co-DETR, ConvNext)

3. Reverse Eng.

결과물 (Red Box) 분석
→ 문제점 역추적

4. Optimization

TTA & WBF 적용
최종 1% 성능 향상

Model Selection: Survival of the Fittest

🔍 Exhaustive Search

"편견 없는 벤치마킹"

- ✅ **MMDetection Hub:** 표준화된 실험 환경 구축을 위해 메인 플랫폼으로 채택.
- ✅ **Broad Search:** YOLO, DINO, Cascade R-CNN 등 다양한 아키텍처를 Trash 데이터셋에 실험.
- ✅ **Criteria:** 오직 Public LB mAP 점수만을 기준으로 생존 모델을 선별했습니다.

Baseline Experiment Leaderboard

Model	Public LB mAP	Status
YOLO v11	0.4010	Drop
Faster R-CNN (Base)	0.4033	Drop
Faster R-CNN (ResNet 50v2)	0.4664	Drop
Faster R-CNN (Swin)	0.5393	Drop
Cascade R-CNN (ConvNeXt-B)	0.5830	Survivor 🏆
ConvNeXt V2	0.6671	Survivor 🏆
Co-DETR	0.7351	Survivor 🏆

Basic Tuning: Universal Enhancements



Resolution Up-scaling

512px → 1024px

학습 이미지 해상도를 확대하여 실제 테스트 이미지 환경과 일치시키고, 고해상도에서 작은 쓰레기 객체의 탐지 성능을 높였습니다.



Weight Upgrade

ImageNet-1k → 21k

훨씬 더 방대한 데이터(21k classes)로 사전 학습된 가중치를 적용하여 Feature Extraction 능력을 강화했고, 이는 즉각적인 mAP 향상으로 이어졌습니다.




Extreme Thresholding

Confidence Thr 0.3 → 0.001

"High Recall Strategy". 모델이 추적하는 모든 물체를 놓치지 않고 병합하는 전략을 사용하여 mAP Metric 상에서 고득점을 달성 (적중)했습니다.

Optimization: Threshold & Weighted Confidence



Tuning the Sensitivity

 **Experiment : Threshold 0.3 → 0.01**


mAP는 큰 폭으로 상승했으나, Recall/Precision Trade-off가 무너지며 **False Positive**가 급증하는 부작용(Noise)이 발생했습니다.

 **Solution: Weighted Confidence**

단순히 Threshold만 낮추는 대신, **Confidence Score**에 가중치를 적용하여 신뢰도 분포를 보정했습니다.

"Weighted Confidence 적용 후, Noise를 억제하면서도 mAP 상승분을 유지하는 확실한 근거를 확보했습니다."

Optimization: Threshold & Weighted Confidence



Tuning the Sensitivity

 **Experiment : Threshold 0.3 → 0.01**

mAP는 큰 폭으로 상승했으나, Recall/Precision Trade-off가 무너지며 **False Positive**가 급증하는 부작용(Noise)이 발생했습니다.

 **Solution: Weighted Confidence**

단순히 Threshold만 낮추는 대신, **Confidence Score**에 가중치를 적용하여 신뢰도 분포를 보정했습니다.

"Weighted Confidence 적용 후, Noise를 억제하면서도 mAP 상승분을 유지하는 확실한 근거를 확보했습니다."

| Ensemble Strategy: Precision Tuning

Weighted Box Fusion (WBF)

"단순 투표가 아닌, 최적의 좌표 융합"

- ✓ **Concept:** 단순 NMS나 Voting 방식이 아닌, 겹치는 박스들의 좌표를 **Confidence Score 가중치**로 융합 (Fusion)하여 더 정확한 위치를 도출합니다.
- ✓ **Effect:** 고성능 모델에 더 높은 가중치를 부여하여, 여러 모델의 예측을 정교하게 보정하고 최종 Localization 성능을 극대화했습니다.

Hyperparameter Tuning

"타협 없는 엄격한 기준"

- ✓ **IoU Threshold (0.55):** 겹치는 박스를 병합할 때, IoU 기준을 0.55로 빡세게 조여 불필요한 중복 박스를 과감히 제거했습니다.
- ✓ **Confidence Type:** 'Average'와 'Max' 방식을 비교 실험하며 파라미터를 튜닝했고, 우리 데이터 분포에서 최고점이 나오는 방식을 채택하여 점수를 깼습니다.

Final Strategy: The Winning Formula

✎ Extensive Grid Search

수많은 가설 검증을 통해 최적의 파라미터를 탐색했습니다.

- ✓ **Weights:** Co-DETR 비중(50%~85%) 조절 및 서브 모델 조합 테스트
- ✓ **IoU Thr:** 0.55 ~ 0.65 구간 정밀 타격 (0.55 채택)
- ✓ **Metric:** 'Max' vs 'Avg' Score Aggregation 비교 ('Max' 채택)

Final Candidates

안정성을 위한 3-Model 조합과 다양성을 위한 4-Model 조합, 두 가지 전략으로 최종 제출을 감행했습니다.

🏆 Strategy 1: Golden Ratio (Safe)

3 Models

Co-DETR(60%) + V2(30%) + V1(10%)

Public: 0.7450 Private: 0.7381

FINAL WINNER

🏆 Strategy 2: Diversity (4-Model)

4 Models

Co-DETR(50%) + Pseudo(15%) + V2(25%) + V1(10%)

Public: 0.7455 Private: 0.7395

Trial & Error: The Pseudo-Labeling Trap?

The Final Squeeze Strategy

대회 막판, 0.0xx 단위의 점수 개선을 위해 **Test Set Self-Training**을 시도했습니다.

- ✓ **Step 1:** 기존 앙상블 모델로 Test Set 추론 (Confidence > 0.9 필터링).
- ✓ **Step 2:** 필터링된 데이터를 정답지(Pseudo-label)로 간주하고 재증강(Re-augmentation)하여 모델 학습.
- ✓ **Step 3:** 해당 모델에 TTA(Test Time Augmentation) 적용 후 추론.

Result: A Twist in the Tale

실험 당시 점수는 하락했으나, 규정에 따라 **최종 2개의 모델**(기존 앙상블, Pseudo-labeling)을 제출했습니다.

Post-Competition Review

"놀랍게도 **Private Leaderboard**에서는 점수가 더 낮았던 Pseudo-labeling 모델이 오히려 더 높은 성능을 기록했습니다."

Overfitting이라 판단했던 모델이 왜 실전(Private LB)에서 더 강했는지, 그 원인에 대해서는 **추가적인 리서치**가 필요한 흥미로운 과제로 남겨두었습니다.

Analysis: 결과로부터 원인을 찾다

Raw Output (The Red Mess)

모델이 뱉어낸 결과는 난장판이었습니다. (최대 477개 박스)


- ✓ **현상:** 확신이 없는(Low Score) 박스를 무수히 생성.
- ✓ **분석:** "에러인가?" **No.**
mAP 점수를 올리기 위한 모델의 필사적인 노력(Recall 확보)입니다.

Decision

억지로 억제하지 않고, **후처리(Post-processing)** 단계에서 해결하기로 결정 (User Tunable System).



Solution: User-Centric Tunable System



"High Recall Output + Adjustable Sensitivity"

모델이 가능한 모든 후보를 제안하면, 사용자는 **Confidence Threshold**를 조절하여 필요한 정밀도로 시스템을 튜닝할 수 있습니다. 단순한 고정 출력이 아닌, 현장 상황에 맞게 최적화 가능한 **범용적인 솔루션**을 제공합니다.

| Further Challenges: Production Reality

Inference Latency

"1.26 iteration/s"

- ✓ **Real-time Constraint:** 현재 모델의 추론 속도는 초당 약 1.26회로, 실시간 비디오 스트림을 처리하기에는 무리가 있습니다.
- ✓ **Bottleneck:** Co-DETR와 같은 Heavy Transformer 모델의 연산량과 앙상블 과정(TTA, WBF)이 주요 병목입니다.

Deployment Hurdles

"High Cost & Optimization"

- ✓ **Resource Intensive:** 고성능 GPU 의존도가 높아 엣지 디바이스(Edge Device) 배포가 어렵습니다.
- ✓ **Future Work:** 상용화를 위해서는 **Model Quantization(양자화)**, **Pruning(가지치기)** 또는 TensorRT 등을 활용한 경량화 및 최적화 작업이 필수적입니다.

Competitive Edge: Agility over Scale

Traditional Approach

비교 열위 (Comparative Disadvantage)

- ✓ 인력 부족 (4 vs 6)
- ✓ 깊이 있는 논문 리뷰 시간 부족
- ✓ 복잡한 커스텀 모델링의 한계

Our Strategy

Agile & Parallel Experimentation

- ✓ **Zero Friction:** 불필요한 회의 제거, 즉시 실험
- ✓ **Independence:** 1인 1GPU로 독립적 실험 수행
- ✓ **Volume:** 이론 검증 대신 실험 횟수로 압도

"우리는 더 깊게 파는 대신, 더 많이 시도했습니다."

| Growth as AI Engineers

1st

Private Leaderboard

Performance (Competition)

mAP 0.7395 달성. High Recall 전략을 통해 극한의 성능을 확보했습니다.

Value (Business)

사용자가 Threshold로 정밀도를 조절 가능한 **Tunable System** 납품. 실무적 가치를 창출했습니다.