

Hand Bone Image Segmentation

Wrap Up Report

Team: CV_05

1. 프로젝트 개요 (Project Overview)

1.1. 프로젝트 주제

- 주제: X-ray Hand Bone Image에서 **Multilabel Semantic Segmentation Task** 수행
- 목표: 경계가 모호하고 크기가 다양한 뼈 간의 Segmentation을 통해 높은 Dice Score달성
- 핵심 전략: 각자 다른 아키텍처를 탐색 후, 상위 모델을 선별하여 앙상블 수행

1.2. 프로젝트 배경

의료 데이터 특유의 **클래스 불균형**과 **경계의 모호함**을 해결하는 것이 필요, Pisiform(콩알뼈)과 같이 픽셀 비중이 매우 낮은 작은 뼈나, 여러 뼈가 복잡하게 겹쳐 있는 손목 부위의 인식 실패를 방지하기 위해, 데이터 분석에 기반하여 **학습 및 추론 전략을 고도화**하는 방향으로 접근함.

2. 팀 구성 및 역할

팀원	역할	담당 파트
김민석B_T8026	AI Engineer	pytorch lightning 통한 파이프라인 개선 및 고도화, eda, data augmentation
박동수_T8071	AI Engineer	GPU 기반 고속 전처리파이프라인 구축 및 학습 병목 해결, SegFormer 기반 아키텍처 고도화(Aux Head) 실험
손준서_T8105	Model Research	뼈 경계선 강화를 위한 CLAHE 및 GC 기반 데이터 증강, 소형 객체 중첩으로 인한 한계 극복을 위한 Custom Loss 기반 가중치 최적화, 모델 구조에 따른 앙상블 시도
이범석_T8143	Model Research	HRNet 모델 학습 및 finetune, 성능 향상을 위한 후처리 실험(custom threshold), validation fine-tuning, 하이퍼파라미터(LR, epoch, optimizer 등)에 따른 성능 비교,모델 확장 및 비교, hard voting

3. 문제 정의 (Problem Definition)

3.1. 데이터의 난관




Figure 3.1.1. Multilabel Class for Hand Bone Image

1. **Class Collapse and Wrist Bone Overlap:** 단순 Loss 결합(BCE+Dice)시 일부 클래스에서 모델이 배경으로 오인하여 아예 예측하지 못함 (**Dice Score 0.00**). Loss 개선으로 손가락 뼈의 검출은 성공했으나, 해부학적 중첩이 심한 손목뼈 구간에서는 여전히 경계면이 모호하여 점수 상승이 정체됨.

	Bone Class	Dice Score
24	finger-1	0.740755
25	finger-3	0.735097
26	finger-18	0.730713
27	finger-13	0.000000
28	finger-12	0.000000

Figure 3.1.1.1 Class Collapse

	Bone Class	Dice Score
24	Triquetrum	0.961643
25	Hamate	0.960708
26	Trapezium	0.960600
27	Trapezoid	0.938098
28	Pisiform	0.935581

Figure 3.1.1.2. Wrist Bone Overlap

2. **Low Contrast & Ambiguity:** X-ray 특성상 뼈와 주변 조직, 혹은 뼈끼리의 경계가 흐릿하여 모델이 확신을 갖지 못하는 문제 발생.

3.2. 인사이트

- 기존 baseline의 512x512의 Resize로는 디테일한 경계 인식에 한계가 있음.
- Low class에 대한 Dice를 끌어올릴 방법이 필요.

4. EDA 및 전처리 (EDA, Data Preprocessing)

4.1. EDA and Decision

- **관찰:** 일부 클래스(Pisiform 등)의 예측 확률(Max Prob)이 0.1~0.2 수준으로 낮아, 일반적인 Threshold(0.5)로는 마스크가 생성되지 않음. 반지, 네일아트, 철심 등의 노이즈가 존재하는 data가 몇몇 관찰됨.

4.2. Data Leakage Prevention

- **관찰:** 데이터셋 내에 동일 인물의 왼손과 오른손 X-ray 이미지가 함께 존재함을 확인.
- **문제:** 인체의 좌우 대칭성으로 인해, 동일 인물의 왼손이 학습셋에, 오른손이 검증셋에 들어갈 경우 모델이 뼈 구조를 암기하여 평가 점수가 부풀려지는 과적합 발생.
- **결정: Group K-Fold 적용.** 환자 ID(폴더명)를 기준으로 그룹을 설정하여, 동일 인물의 데이터가 학습과 검증 단계에서 섞이지 않도록 분리함.

4.3. Data Preprocessing and Augmentation

- **Resolution Up-scaling:** 해상도를 512px 이상으로 확대하여 모델의 전체적인 성능 향상.
- **Change Loss Function:** 기존의 BCE Loss를 단독으로 사용하는 것은 학습시킨 각 모델에 적합하지 않기 때문에 모델에 맞는 최적의 Loss를 찾기 위해 실험 및 적용.
- **CLAHE:** 이미지의 국소적인 대비를 강화하여 X-ray 상에서 뼈와 연조직 사이의 모호한 경계선을 뚜렷하게 만들고, 겹쳐진 손목뼈의 분리 성능을 개선함.
- **Random Gamma Correction:** 영상의 밝기 값을 비선형적으로 조절하여, 촬영 환경에 따라 달라지는 X-ray 명도 차이에 구애받지 않는 강건한 모델을 만듦.
- **Geometric Augmentation:** 회전, 이동, 크기 조절 등을 무작위로 적용하여, 환자마다 제각각인 손의 위치와 다양한 뼈 크기에 대한 모델의 대응력을 높임.
- **Grid Distortion:** 이미지에 격자 형태의 미세한 왜곡을 주어, 사람마다 조금씩 다른 뼈의 생김새나 관절이 꺾인 각도까지 모델이 유연하게 학습하도록 유도함.

5. 프로젝트 결과 (Results)

5.1. 정량적 성과

- **Private Leaderboard:** Dice Score **0.9752**. 1위(0.9769)와 0.0017의 근소한 차이로, 상위권 모델들과 대등한 성능 수준을 확보하여 경쟁력도 충분.
- **성과 요인:** 단일 모델의 한계를 극복하기 위한 **Ensemble** 전략과, 소형 객체 소실(Class Collapse)을 방지한 **Custom Loss** 설계가 주요했음. 또한 각 모델의 구조적 이질성(CNN, Transformer)이 상호보완적인 효과와 일반화 성능 향상을 낸 것으로 보임.

5.2. 정성적 성과: Robustness for Hard Cases

- **해부학적 난제 해결:** 기존 모델들이 어려워했던 중첩된 손목뼈와 미세 손가락 관절의 경계를 명확히 분리해냄.
- **Data-Centric Optimization:** 단순히 모델의 체급을 키우는 것 이상으로, CLAHE 및 Gamma Correction 등 데이터 특성에 맞춘 전처리를 통해 "**보이지 않는 것을 보이게 만드는**" 해결책을 제시.
- **엔지니어링 철학:** SOTA 모델 맹신을 버리고 데이터에 기반한 가설 검증 프로세스 확립.

6. 한계점 및 향후 과제 (Limitations)

6.1. Inference Efficiency (Hard Voting의 한계)

- **문제:** 최종 앙상블을 hard voting으로 수행했기 때문에 soft voting의 기댓값보다 낮은 결과가 나왔다고 보임. 대신 속도에서는 각 모델의 추론시간이 약 5분이고 hard voting의 시간이 약 3분이었기에 충분히 효율적.
- **원인:** 근본적으로 hard voting은 각 모델이 예측한 픽셀별 confidence는 소실되고 다수결로만 판단하기 때문에 확신을 갖고 예측한 답과 불확실하게 예측한 값이 동등하게 취급되기 때문에 이런 한계가 발생.

6.2. Future Work: 개발 표준화 및 협업 효율성

- **Unified Pipeline 구축:** 프로젝트 초기에 Base code를 작성하고, git과 같은 협업 툴을 통해 표준화된 작업 환경을 구현하고 효율적인 협업과 실험 관리를 실현.

7. 자체 평가 및 회고

7.1. 팀 회고

7.1.1. 잘한 점

- **데이터 중심의 문제 해결:** 모델 아키텍처를 교체하는 것에 그치지 않고, CLAHE, Gamma Correction 등 전처리를 통해 '보이지 않는 빠'를 보이게 만드는 근본적인 해결책에 집중함.
- **모델 아키텍처 전환:** 초기 SOTA 모델의 학습 불안정성을 파악하고 배제함. 검증된 아키텍처로 회귀하여 최적화에 집중한 전략이 유효했음.
- **시각적 검증:** 추론 결과를 시각화하여 정규화 오류나 이중 나뭇섬 문제를 발견하고 해결하는 등 꼼꼼한 디버깅 습관을 정착시킴.
- **상호 보완 앙상블:** 팀원 각자의 모델(CNN vs Transformer) 특성을 파악하여, 국소 정보와 전역 정보를 결합하는 전략을 통해 단일 모델의 한계를 극복함.

7.1.2. 아쉬운 점

- **고해상도 전략의 늦은 도입:** 프로젝트 초반 2048px 원본 학습에 집착하여 많은 시간을 소모함.
- **후처리의 기술적 깊이 부족:** 단순 임계값 조절을 넘어, 빠의 기하학적 구조를 고려한 CRF나 성분 분석 등 심도 있는 후처리 연구가 부족했음.
- **일정 관리의 부족:** 초기 mmsegmentation을 적용하려는 시도가 실패로 돌아가는 과정에서 적지 않은 시간을 소모하여 차후 실험 전개과정에서 시간적 제약으로 인해 영향을 받았음

7.1.3. 시도할 점

- **지식 종류를 통한 모델 최적화:** 무거운 앙상블 모델의 성능을 유지하면서도 가벼운 단일 모델로 압축하여, 엣지 디바이스에서도 구동 가능한 경량화 모델 개발 시도.
- **고도화된 후처리 연구:** 픽셀 단위 분류를 넘어, 빠와 빠 사이의 연결성이나 해부학적 제약 조건을 손실 함수나 후처리 단계에 반영하는 기법 도입.
- **교차 검증의 정례화:** Public 리더보드와 Validation의 괴리를 줄이기 위해, 5-Fold 교차 검증을 기본 프로세스로 정착시켜 모델의 일반화 성능을 객관적으로 담보.

7.2. 개인 회고 (Personal Retrospective)

김민석_T8026 (EDA, model training)

- **학습 목표 및 수행:**
 - **목표:** 효율적인 실험 환경 조성 and 코드 구조 개선을 통한 모델 성능 향상.
 - **수행:** 단일 베이스라인을 모듈화하여 다양한 기능으로 나누고, 데이터 로딩 개선 및 테스트 환경 구축을 위한 소형 샘플 데이터 세트 분리 작업 수행. Pytorch 기반 코드를 Pytorch Lightning으로 전환하여 생산성을 높임.
- **모델 개선 방식:**
 - **데이터 처리:** JSON 디코딩 시 발생하는 병목 현상을 해결하기 위해 미리 생성한 마스크 파일을 사용하고, 폴더 접근과정에서 glob 라이브러리를 사용하여 베이스라인 코드를 개선함
 - **구조적 개선:** train, validation, prediction 데이터셋을 별도의 데이터 모듈로 나누고, YAML 파일을 통해 설정 관리를 가능하게 함. Hydra를 활용하여 폴더 구조 관리 및 K등의 GPU 활용을 위한 파이프라인 개선 작업 수행.
- **성과 및 깨달음:**
 - **성과:** Custom Loss 함수를 정의하고 이를 nn.Module 상속 클래스로 모듈화함으로써 성능을 개선하였으며, W&B 및 Early Stopping을 활용한 학습 추적 환경을 구축하여 실험의 효율성을 높임.
 - **깨달음:** 효율적인 실험 환경 구축의 중요성을 인식하고, 데이터 처리 및 모델 훈련 과정을 최적화함으로써 작업에 기초가 되는 프로세스를 마련하게 됨.
- **한계 및 아쉬움:**
 - **개발 구조:** 파이프라인 개선에 시간이 소요되어 실험 시간이 부족하였고, 스케줄러 커스터마이징이 불완전하여 원하는 결과를 도출하지 못함.
 - **협업:** 초기 MMsegmentation 도입 시도에서의 시간 손실로 인해 실험 성과가 감소하였고, 앙상블 구조가 복잡하여 후속 작업의 유연성이 떨어짐.
- **향후 계획:**
 - **역량:** 데이터 증강 및 프로세스 최적화 기술을 더욱 향상시켜, 향후 프로젝트에서의 실험 환경 관리 능력 강화.
 - **표준화:** Docker 및 요구 사항 관리 체계를 도입하여 실험 환경의 일관성을 높이고, 협업의 효율성을 증대시키기 위한 구조 정립.
 - **고도화:** 확장성과 유지 보수성을 지키는 베이스라인 코드로 개선 예정

박동수_T8071 (Model Research)

- **학습 목표 및 수행**

- **목표:** Segmentation 프레임워크(SMP, MMSegmentation)의 구조적 이해 및 베이스라인 코드의 커스터마이징 능력 확보.
- **수행:** PyTorch 기반 파이프라인 재구축 및 다양한 모델(FPN, SegFormer 등) 실험 진행. GPU 리소스 효율화를 위한 하드웨어 벤치마크 수행 및 최적화 기술 도입.

- **모델 개선 방식**

- **속도 및 리소스 최적화 (성공):**
 - **AMP & GA:** AMP 적용으로 VRAM 약 13.5% 절감(FPN 기준) 및 Gradient Accumulation을 통해 물리적 배치 한계 극복.
 - **DALI & Kornia:** CPU 병목(Data Starvation) 해결을 위해 DALI를 도입하여 데이터 로딩 속도 단축(53초 -> 7초). Kornia를 활용해 GPU 기반의 고속 증강(미세 회전, 노이즈) 파이프라인 구축.
- **아키텍처 고도화 (검증 미비):**
 - **Class Decoupling (가설 검증):** 멀티 디코더 구조 도입에 앞서 타당성을 검증하기 위해, 클래스를 물리적으로 나누어 분리 학습(Split Training)을 시도했으나 데이터 결함으로 효용성 입증 실패.
 - **Aux Head:** 경계선 인식 강화를 위해 윤곽선을 학습하는 보조 헤드 도입.

- **성과 및 핵심 깨달음**

- **파이프라인 효율화 경험:** AMP와 DALI 등을 활용해 학습 속도와 메모리 효율을 개선하는 과정을 통해 시스템 관점의 엔지니어링 경험을 쌓음.
"Garbage In, Garbage Out": 전처리 단계의 사소한 논리적 오류가 고도화된 모델 아키텍처(Multi-Decoder 등)도 무용지물로 만들 수 있음을 뼈저리게 체감함.

- **한계 및 아쉬움**

- **싱글 라벨(Single-Label) 학습의 오류:** 초기 데이터 가공 실수로 싱글 라벨 마스크를 사용하여 학습을 진행함. 이로 인한 성능 정체를 모델 문제로 오인하여 유효하지 않은 실험에 시간을 소모함.
- **실험의 무효화 및 시간 부족:** 프로젝트 막바지에 데이터 생성 로직 결함을 발견하고 수정했으나, 시간 부족으로 재학습을 완료하지 못함.

- **향후 계획**

- **데이터 검증 프로세스 정립:** 학습 시작 전, 데이터의 형상(Shape)과 레이블 분포를 시각화하여 전처리 로직의 무결성을 검증하는 절차 의무화.

👤 손준서 (AI Research & Model Optimization)

"SOTA 모델 그 이상을 요구했던 디테일의 싸움." (Top 0.9769 vs Team 0.9752)

- 학습 목표 및 수행:

- 목표: 단순한 모델 교체를 넘어, 데이터 특성에 기반한 논리적 가설 검증 프로세스 체화.
- 수행:
 - [시행착오와 방향 전환] Mamba(VM-UNet) 아키텍처에 주목하여 도입을 시도했으나, 학습 불안정성과 라이브러리 호환성 문제를 겪으며 검증된 아키텍처(MaxViT, HRNet)의 최적화로 전략을 수정함.
 - [가설 검증] 2048px 고해상도 학습이 필수적이라는 가설 하에 Baseline부터 단계적으로 실험을 설계하여 성능 향상의 인과관계를 파악하는 데 주력함.

- 모델 개선 방식:

- 데이터 (Data-Centric): 전체 Dice Score는 높았으나 손목뼈(Trapezoid, Pisiform) 등 겹침이 심한 부위에서 점수 손실이 발생함을 확인.
- 이를 보완하기 위해 CLAHE 및 Random Gamma Correction을 적용하여 경계선 가시성을 높이고, **CNN(HRNet)과 Transformer(MaxViT)의 상호 보완적 앙상블 전략을 통해** 미세 뼈의 검출 정밀도를 개선함.
- **Loss Engineering:** 소형 객체에 대한 재현율을 확보하기 위해 Tversky Loss와 Focal Loss를 결합하고, 손목뼈 클래스에 가중치를 부여하는 **Class Boosting** 기법 적용.

- 성과 및 깨달음:

- 성과: 초기 시행착오를 극복하고 모델 앙상블을 통해 Dice score 0.9752를 달성.
- 깨달음: 1위(0.9769)와의 0.0017 차이는 모델 성능보다는 얼마나 데이터를 깎아냈는가의 차이였음을 체감함.

- 한계 및 아쉬움:

- 시간 관리: 프로젝트 초반, 새로운 아키텍처 도입과 환경 설정에 다소 많은 시간을 할애하여, 후반부 Post-processing에 충분한 시간을 쏟지 못한 점이 아쉬움으로 남음.

- 향후 계획:

- **Post-processing 심화:** 모델 출력값을 단순히 Thresholding 하는 것을 넘어, 픽셀 간의 연관성(CRF)이나 기하학적 특성을 활용한 후처리 기법을 심도 있게 연구.

👤 이범석_T8143 (Model Research & Data Analysis)

“데이터의 형태에 맞는 기법과 후처리가 성능을 결정한다”

- **학습 목표 및 수행:**

- **목표:** Why에 기반한 가설 검증을 통해 모델에 맞는 적절한 기법을 통해 성능을 향상.
- **수행:** 모델을 학습한 뒤 결과를 분석. 그에 따른 가설을 설정한 뒤, 실험을 통해 검증하여 모델을 성능을 향상시켰고 변인통제를 통해 원인과 결과를 확실하게 추론할 수 있게 함.

- **모델 개선 방식:**

- **Hybrid Loss Strategy:** Class Imbalance가 심한 X-ray 데이터 특성상 단일 Loss로는 학습이 불안정함을 확인. **Focal Loss**와 **Dice Loss**를 결합하여 소형 객체의 검출력과 학습 안정성을 동시에 확보.
- **Validation Fine-tuning :** Train Set으로 수렴된 모델에 Validation Set을 추가 학습(Fine-tuning)하는 전략을 도입. Epoch 수(5, 10, 15)를 조정하여 과적합 없이 모델의 일반화 성능을 극대화하는 **Optimal Point**를 도출.
- **Adaptive Thresholding:** 모델의 예측 확률 분포를 분석하여 **Pisiform, Scaphoid** 등 확신도가 낮은 Class에 **개별 임계값**을 적용. 재학습 없이 후처리만으로 **성능 향상**.
- **Error Analysis:** 단순히 점수가 낮은 Class를 찾는 것에 그치지 않고, "경계가 흐릿해서인가, 객체가 작아서인가?"를 분석. 이를 통해 **Sharpen Augmentation**과 **Flip**을 적용하여 취약점을 보완함.

- **성과 및 깨달음:**

- **성과:** HRNet-W48 단일 모델 기준 **Public LB 0.9711** 달성
- **깨달음:** 적절한 학습 환경이 뒷받침될 때, **입력 해상도(1024px)**와 성능은 **비례함**을 입증하였고 모델 학습이 끝난 후에도, 데이터에 대한 통찰만 있다면 성능을 한 단계 더 끌어올릴 수 있음을 체감.

- **한계 및 아쉬움:**

- **실험 관리:** 팀원 간 코드 베이스와 라이브러리가 통일되지 않아, 최종 앙상블 단계에서 성능 기대값이 더 높은 **Soft Voting**을 적용하지 못하고 **Hard Voting**에 그친 점이 아쉬움.

- **향후 계획:**

- **MLOps & Standardization:** 실험의 재현성을 보장하고 협업 효율을 높이기 위해,

프로젝트 초기부터 입출력 인터페이스를 통일하고 실험 기록을 체계화하는
MLOps 환경 구축을 시도해보고 싶음.